

이산 다변량분포 (Discrete Multivariate Distributions)

출처: Encyclopedia of Actuarial Science (Wiley, 2004)

읽는 법. 본문은 원문 표제어의 내용을 그대로 옮긴 것입니다. 회색 **해설** · **예제** 상자는 학부 입문 학습을 돕기 위해 **새로 추가한 부분**이며, 원문에는 없습니다. 처음 보는 용어는 글 끝 **부록(보험·통계 용어 풀이)**을 참고하세요.

※ 원문은 22쪽에 이르는 서베이(개관) 논문입니다. 이 해설서는 보험계리 학습에 중요한 핵심 — 주요 분포족의 정의·적률·성질 — 을 중심으로 간추린 요약본입니다.

1. 표기와 서론 Definitions and introduction

k 차원 이산 확률벡터 $X=(X_1, \dots, X_k)^T$ 에 대해 확률질량함수 $P_X(x)$, 확률생성함수 $G_X(t)=E\{\prod_{i=1}^k t_i^{X_i}\}$, 적률생성함수 $M_X(t)=E\{e^{t^T X}\}$, 누율생성함수 $K_X=\log M_X$, 특성함수 $\phi_X(t)=E\{e^{it^T X}\}$ 를 쓴다. r 차 혼합 원적률 $\mu'_{[r]}$, 중심적률 μ'_r , **하강 계승적률** $\mu'_{(r)}(X)=E\{\prod_{i=1}^k X_i^{(r-i)}\}$ ($X^{(r)}=X(X-1)\cdots(X-r+1)$), 상승 계승적률 $\mu'_{[r]}$, 혼합 누율 κ_r 등이 기본 도구다. 단변량 이산분포에 비해 이산 **다변량분포**의 연구는 "적다(little)"고 했던 콕스의 평은 지금도 "덜하다(less)" 정도로만 바꿀 수 있다고 존슨-코츠-발라크리슈난은 말한다. 이산 다변량분포 — 특히 다항분포 — 는 **지급준비금 산정과 재보험** 응용에서 관심이 크다.

적률 사이의 관계. 계승적률과 원적률은 **스털링 수**로 오간다 — 1종 �털링 수 $s(n, \ell)$ 로 $\mu'_{(r)}$ 를 μ' 들의 합으로, 2종 �털링 수 $S(n, \ell)$ 로 $\mu'_{[r]}$ 을 $\mu'_{(\ell)}$ 들의 합으로 쓸 수 있고(식 5-10), 이항전개로 중심적률-원적률-누율 사이의 관계도 닫힌 형태로 얻는다. 한 종류의 적률을 알면 다른 모든 종류를 기계적으로 얻을 수 있다는 뜻이다.

조건부·팽창·절단 분포. 조건부 확률생성함수의 일반 공식이 있고, 특정 값(보통 0)의 확률을 부풀린 **팽창(inflated) 분포** — 보험에서는 무클레임 확률을 키우는 영팽창(zero-inflated) 모형 — 와, 변수 일부를 제약한 **절단(truncated) 분포**도 같은 틀에서 다룬다.

2. 다항분포 Multinomial distributions

n 번의 독립 시행에서 k 개의 범주가 각각 확률 $p_1, \dots, p_k$ 로 나올 때 범주별 도수 X 의 분포:

$$P_X(x) = \frac{n!}{x_1! \cdots x_k!} \prod_{i=1}^k p_i^{x_i}, \quad G_X(t) = \left(\sum_{i=1}^k p_i t_i \right)^n \quad (32, 35)$$

하강 계승적률은 $\mu'_{(r)}(X) = n^{(\sum r_i)} \prod p_i^{r_i}$ 로 닫힌 형태이고(식 37), 이로부터

$$E(X_i) = np_i, \quad \text{Var}(X_i) = np_i(1 - p_i), \quad \text{Corr}(X_i, X_j) = -\sqrt{\frac{p_i p_j}{(1 - p_i)(1 - p_j)}} \quad (38)$$

이다 — **상관이 항상 음수**이고(한 범주가 늘면 다른 범주가 줄 수밖에 없다) 분산-공분산 행렬은 계수 $k-1$ 의 특이 행렬이다. 주변분포는 이항, 부분벡터(나머지를 묶은)는 다시 다항, 조건부 분포도 다항이어서 회귀가 **선형**이다(분산은 이분산적). 같은 p 의 독립 다항분포의 합은 다시 다항 — **지표 n 에 대한 재생성** — 하지만 p 가 다르면 성립하지 않는다. 엔트로피는 등확률($p=1/k$)에서 최대이고, $P(\cap\{X_i \leq c_i\}) \leq \prod P\{X_i \leq c_i\}$ 류의 부등식들이 성분 간 **음의 종속**을 확립한다.

계산·근사·특성화. 꼬리확률은 불완전 디리클레 적분으로 표현되고(올킨-소벨), 국소 전개에서 $n^{-1/2}$ 항을 버리면 친숙한 **카이제곱 근사**

$$P_X(x) \approx (2\pi n \prod p_i)^{-1/2} e^{-\chi^2/2}, \quad \chi^2 = \sum_{i=1}^k \frac{(x_i - np_i)^2}{np_i} \quad (49, 50)$$

가 나온다 — 적합도 검정 통계량의 기원이다. $Y=X/n$ 에 디리클레 밀도를 쓰는 존슨의 근사는 1·2차 적률을 정확히 맞춘다. **볼셰프의 특성화:** 독립 비음 정수값 변수들이 비퇴화 포아송일 필요충분조건은 합이 주어졌을 때의 조건부 분포가 비퇴화 다항인 것 — 시뮬레이션(브라운-브롬버그의 2단계 알고리즘)에도 쓰인다. 추정은 베이지 접근에서 **디리클레 사전분포**가 표준이며, p 에 디리클레를 섞으면 **디리클레-복합 다항분포**(= 다변량 폴리아; 음의 다변량 초기하라고도 부른다)가 나온다. 과대산포 범주형 자료에는 다항의 유한혼합이 쓰인다.

3. 음의 다항분포 Negative multinomial distributions

확률생성함수가

$$G_X(t) = \left(Q - \sum_{i=1}^k P_i t_i \right)^{-n}, \quad Q - \sum P_i = 1, \quad n > 0 \quad (57)$$

인 분포(다변량 음이항이라고도 한다; n 은 분수도 가능). $p_0=1/Q$, $p_i=P_i/Q$ 로 쓰면

$$P_X(x) = \frac{\Gamma(n + \sum x_i)}{\Gamma(n) x_1! \cdots x_k!} p_0^n \prod_{i=1}^k p_i^{x_i} \quad (59)$$

이다. 계승적률에서 상관계수는

$$\text{Corr}(X_i, X_j) = \sqrt{\frac{p_i p_j}{(1 + p_i)(1 + p_j)}} > 0 \quad (66)$$

로 **항상 양수** — 다항분포(항상 음수)와 정반대다. 부분벡터도 음의 다항이고, 회귀는 모두 선형이며, **합 $N=\sum X_i$ 가 주어지면 조건부 분포는 다항**이고 N 자체는 단변량 음이항이다. 최대우도 추정 방정식(식 69-71)이 정리되어 있고, 디리클레를 섞은 디리클레-복합 음의 다항분포도 비슷한 성질을 갖는다.

해설 부호가 말해주는 용도

"총 n 건을 범주에 나눠 담는" 다항형 상황은 음의 상관(제로섬)을, "공동 충격·공동 강도 아래 각 범주가 함께 늘어나는" 음의 다항형 상황은 양의 상관을 낳는다. 여러 담보의 클레임 건수가 함께 출렁이는 포트폴리

오라면 음의 다항(또는 아래의 다변량 포아송·혼합 포아송)이 자연스러운 후보다. 음의 다항은 감마 혼합 다변량 포아송으로도 얻어진다 — 단변량에서 "감마 혼합 포아송 = 음이항"의 다변량 판이다.

다변량 베르누이·이항. 0/1 벡터의 일반 분포(다변량 베르누이)는 2^k 개의 확률로 지정되며(토이겔스의 정수 대응), i.i.d. 다변량 베르누이 n 개의 합이 **다변량 이항분포**다.

4. 다변량 포아송 분포 Multivariate Poisson distributions

이변량(홀게이트 구성). 독립인 $Y_1 \sim \text{포아송}(\theta_1)$, $Y_2 \sim \text{포아송}(\theta_2)$, $Y_{12} \sim \text{포아송}(\theta_{12})$ 로

$$X_1 = Y_1 + Y_{12}, \quad X_2 = Y_2 + Y_{12} \quad (77)$$

를 만들면 주변분포는 포아송($\theta_1 + \theta_{12}$), 포아송($\theta_2 + \theta_{12}$)이고 결합 질량함수는 식 (78)의 합 형태다. 질량함수는 재귀식

$$x_1 P(x_1, x_2) = \theta_1 P(x_1 - 1, x_2) + \theta_{12} P(x_1 - 1, x_2 - 1) \quad (79)$$

을 만족하는데, 이는 판여 재귀를 일반화한 **헤셀라거의 이변량 계수분포 재귀**의 특수경우다 — 보험 총클레임 계산과의 접점이다. 공분산은 $\text{Cov}(X_1, X_2) = \theta_{12}$ (공통 충격의 분산)이고

$$\text{Corr}(X_1, X_2) = \frac{\theta_{12}}{\sqrt{(\theta_1 + \theta_{12})(\theta_2 + \theta_{12})}} \quad (83)$$

는 $\theta_{12} \in \{0, \min(\theta_1, \theta_2)\}$ 을 넘지 못한다 — **양의 상관만, 그것도 제한된 범위만** 가능하다. 조건부 분포는 "포아송 + 이항"의 독립합이어서 회귀는 선형, 산포는 이분산적이다(식 85-86). 최대우도 추정에서 θ_{12} 는 다항방정식의 수치해가 필요해, 표본공분산(적률 추정)이나 짝수점법·이중영점법 같은 대안이 쓰인다. k 변량 일반화는 공통 성분 Y 를 더하는 $X_i = Y_i + Y$ 구성이 자연스럽고, 모든 짝·삼중…… k 중 공통항을 갖춘 타이허의 일반형(식 97; 무한분해가능), 모든 주변이 포아송인 루카치-비어 형태 등이 있다. 포아송 모수에 분포를 입힌 **복합(혼합) 이변량 포아송**, 일반화 포아송·네이만 A형을 성분으로 쓴 이변량 short-들라포르트 분포, 한쪽 주변이 네이만 A형인 포아송-포아송 분포($G(t_1, G_2(t_2))$ 구조), 두 조건부가 모두 포아송인 유일한 분포(베솔로프스키) 등 변형이 많다.

5. 다변량 초기하분포 Multivariate hypergeometric

m 명 중 유형 G_i 가 m_i 명인 모집단에서 n 명을 **비복원**추출할 때 유형별 표본 수의 분포:

$$P_X(x) = \frac{1}{\binom{m}{n}} \prod_{i=1}^k \binom{m_i}{x_i}, \quad \sum x_i = n \quad (99)$$

$m \rightarrow \infty$, $m_i/m \rightarrow p_i$ 이면 다항분포로 수렴하므로 성질도 닮았다 — 주변은 초기하, 부분벡터·조건부도 다변량 초기하이고, 회귀는 선형(이분산적), **상관은 모두 음수**다(식 101). 모수가 음이 아닌 정수일 필요가 없다는 관찰에서 다변량 역초기하·음의 초기하·음의 역초기하 분포가 정의되고, 일반화 초기하(식 105), 여러 분포를 특수경우로 담는 **통합 다변량 초기하**(스테인 족, 식 106), 등확률 제약점유 모형, 편향 표집에서 나오는 비중심 초기하 등이 파생된다. $X|m$ 을 다변량 초기하, m 에 다항 사전분포를 주면 주변분포가 정확히 다항이 되는 **초기하-다항 모형**은 경험적 베이즈 추론에 쓰인다. 품질관리가 자연스러운 응용 무대다.

6. 다변량 폴리아-에겐베르거 분포 Multivariate Pólya-Eggenberger

항아리에 색 $C_1, \dots, C_k$ 의 공이 $a_1, \dots, a_k$ 개(합 a) 들어 있고, 한 개를 뽑아 색을 확인한 뒤 **같은 색 공 c 개를 더해** 되 돌려 넣기를 n 번 반복할 때 색별 누적 횟수의 분포:

$$P_X(x) = \binom{n}{x_1, \dots, x_k} \frac{1}{a^{[n, c]}} \prod_{i=1}^k a_i^{[x_i, c]}, \quad a^{[y, c]} = a(a+c) \cdots (a+(y-1)c) \quad (110)$$

$c=0$ 이면 **다항분포**(복원추출), $c=-1$ 이면 **다변량 초기하**(비복원추출)로 환원된다 — 두 분포를 잇는 다리다. 적률은

$$E(X_i) = \frac{na_i}{a}, \quad \text{Corr}(X_i, X_j) = -\sqrt{\frac{a_i a_j}{(a - a_i)(a - a_j)}} \quad (115)$$

로 역시 모두 음의 상관이다. $c>0$ 이면 "성공이 성공을 부르는" **전염(contagion) 모형**이 되며, 보험에서 사고 경향성(accident proneness)의 고전적 모형이다.

7. 그 밖의 분포족 Other families

- **다변량 먹급수 분포** — $P(x) \propto a(x) \prod \theta_i^{x_i} / A(\theta)$ 꼴의 통일적 족. 다항·음의 다항·다변량 포아송을 포괄하고 적률·추정의 일반 공식을 준다.
- **다변량 이산 지수족** — 자연모수화로 추론 이론이 정비된 족.
- **가중(weighted) 분포** — $P^W(x) = w(x)P(x)/E[w(X)]$. 크기편향 표집 등 관측 메커니즘의 왜곡을 반영.
- **런(run) 관련 분포** — 사건의 횟수가 아니라 **연속 발생(런·패턴)**의 분포. 최근 20년간 활발히 발전했다.
- 그 밖에 다변량 보렐-탄너, 다변량 라그랑주 포아송, 다변량 일반화 웨어링(생성 위험·외생 위험의 분리에 사용) 등.

예제 상관 부호 빨리 읽기

세 담보(화재·풍수해·도난)의 연간 클레임 건수를 모형화한다. ① 총 점검 횟수가 연 n 회로 고정된 점검 발견 건수, ② 공통 기상충격에 노출된 건수 — 각각 어떤 족이 후보인가?

①은 "고정 총량의 배분"이므로 음의 상관 — 다항·다변량 초기하·폴리아 계열. ②는 "공통 원인의 공유"이므로 양의 상관 — 다변량 포아송(공통 충격), 음의 다항(공통 감마 강도) 계열. **상관의 부호와 생성 메커니즘이 족 선택의 첫 기준**이라는 것이 이 서베이를 관통하는 실용적 교훈이다.

참고 및 관련 표제어

관련 표제어. Discrete Parametric Distributions(이산 모수분포) · Compound Poisson Frequency Models(복합 포아송 빈도모형) · Mixed Poisson Distributions(혼합 포아송 분포) · Continuous Multivariate Distributions(연속 다변량분포) · Dependent Risks(종속위험) · Generalized Discrete Distributions(일반화 이산분포) · Sundt's Classes of Distributions(순트 분포족) · Under- and Overdispersion(과소·과대산포)

원문 참고문헌(발췌). Johnson, Kotz & Balakrishnan, Discrete Multivariate Distributions (Wiley, 1997) · Kocherlakota & Kocherlakota, Bivariate Discrete Distributions (1992) · Johnson, Kotz & Kemp, Univariate Discrete Distributions (1992) · Panjer & Willmot, Insurance Risk Models (1992) · Klugman, Panjer & Willmot, Loss Models (1998) · Holgate (1964) · Teicher (1954) · Olkin & Sobel (1965) · Hesselager, ASTIN Bulletin (1996) 외 100여 편.

부록. 이 글에 나온 용어 (배경지식 보충)

- **계승적률 (factorial moment)** — $E[X(X-1)\cdots(X-r+1)]$ 류. 이산분포에서 원적률보다 다루기 쉽다.
 - **스털링 수** — 거듭제곱과 계승 사이의 변환계수. 적률 종류 간 환산에 사용.
 - **영팽창 분포 (zero-inflated)** — 0의 확률을 따로 부풀린 혼합. 무클레임 과잉 자료의 표준 처리.
 - **재생성 (reproducibility)** — 같은 족의 독립합이 다시 같은 족이 되는 성질.
 - **공통충격 모형 (common shock)** — 공유 성분을 더해 양의 종속을 만드는 구성(홀게이트).
 - **디리클레-복합 (Dirichlet-compound)** — 확률모수에 디리클레를 섞은 분포. 다항이면 다변량 폴리아.
 - **폴리아 항아리** — 뽑은 색을 c 개 더 넣는 강화 추출. 전염·사고경향성의 고전 모형.
 - **멱급수 분포족 (power series)** — 정규화 상수 $A(\theta)$ 의 멱급수로 정의되는 통일 틀.
 - **크기편향 (size-biased)** — 큰 값일수록 관측되기 쉬운 표집. 가중분포의 대표 사례.
-

원문: Encyclopedia of Actuarial Science (Wiley, 2004), “Discrete Multivariate Distributions”, N. Balakrishnan. · 본 해설서의 [해설]·[예제]·[부록]은 학부 입문 학습용으로 추가·구성한 것임. 수식은 원문 기준 복원.