

이산 모수분포 (Discrete Parametric Distributions)

출처: Encyclopedia of Actuarial Science (Wiley, 2004)

읽는 법. 본문은 원문 표제어의 내용을 그대로 옮긴 것입니다. 회색 **해설** · **예제** 상자는 학부 입문 학습을 돕기 위해 새로 추가한 부분이며, 원문에는 없습니다. 처음 보는 용어는 글 끝 **부록(보험·통계 용어 풀이)**을 참고하세요.

1. 계수분포란 무엇인가 Counting distributions

이 글의 목적은 보험 모형화에 쓰이는 대표적인 **계수분포(counting distribution)** 족을 소개하는 것이다. 계수분포란 음이 아닌 정수 0, 1, 2, 3, ...에만 확률이 놓이는 이산분포로, 보험에서는 피보험자의 손실 발생 건수나 보험회사에 접수되는 **클레임 건수**를 기술한다. 클레임의 건수 과정과 금액 과정을 분리해 이해하면 총손실만 아는 경우보다 보험을 둘러싼 여러 문제 — 특히 공제금액·보상한도 같은 **계약조건 변경**의 효과 — 를 훨씬 깊이 다룰 수 있다. 또한 건수 모형은 비교적 얻기 쉽고, 널리 쓰이는 분포들이 실제로 손실 발생 성향을 잘 묘사한다는 경험적 근거도 충분하다.

사건이 정확히 k 번 일어날 확률을 p_k , 사건 수를 확률변수 N 이라 하면 **확률함수(pf)**와 **확률생성함수(pgf)**는 다음과 같다.

$$p_k = \Pr \{N = k\}, \quad k = 0, 1, 2, \dots; \quad P(z) = E[z^N] = \sum_{k=0}^{\infty} p_k z^k \quad (1, 2)$$

해설 pgf는 계수분포의 "지문"이다

pgf는 분포를 유일하게 결정하므로, 두 확률변수의 pgf가 같으면 분포가 같다. 독립합의 pgf는 pgf의 곱이 되고, 미분으로 적률을 뽑아낼 수 있으며($P'(1)=E[N]$), 총클레임 S 의 pgf가 $P_N(P_X(z))$ 로 합성되는 등 빈도 모형의 거의 모든 계산이 pgf를 통해 이루어진다. 아래 각 분포의 pgf 형태를 눈에 익혀 두면 합성분포·재귀 계산 표제어를 읽을 때 큰 도움이 된다.

2. 포아송 분포 Poisson distribution

평균 $\lambda > 0$ 인 **포아송 분포**는 보험 모형화에서 가장 중요한 분포의 하나로, 확률함수와 pgf는

$$p_k = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots; \quad P(z) = e^{\lambda(z-1)} \quad (3, 4)$$

이고 **평균과 분산이 모두 λ** 이다. N_1, N_2 가 평균 λ_1, λ_2 인 독립 포아송이면 $N=N_1+N_2$ 의 pgf는

$$P_N(z) = P_{N_1}(z)P_{N_2}(z) = e^{(\lambda_1 + \lambda_2)(z-1)} \quad (5)$$

이므로 pgf의 유일성에 의해 N 은 평균 $\lambda_1 + \lambda_2$ 인 포아송이다 — 즉 **독립 포아송의 유한합은 다시 포아송**이다(재생성). 따라서 중심극한정리에 의해 λ 가 크면 포아송은 정규분포에 가깝다. 포아송 분포는 **무한분해가능(infinitely divisible)**하며 이는 확률과정 이론에서 핵심적 성질이다. 이런 수학적 장점 때문에 클레임 건수 모형으로 즐겨 쓰이지만, **분산이 평균과 같도록 제약**되어 있다는 점이 관측 자료와 맞지 않는 경우가 많다는 것이 큰 약점이다.

원문 예제 1 (Douglas, 1980). 어느 보험회사의 1년 기록에서 특정 담보에 대해 하루에 발생한 클레임 유발 사고 건수를 집계하였다. 365일 동안 총 742건이 발생했고, 최대우도 추정치는 $\hat{\lambda}=742/365=2.0329$ 이다. 적합 결과는 다음과 같다.

표 1. 일별 클레임 건수의 포아송 적합 (원문 표 1·2 통합)

건수/일 k	관측 일수 n_k	포아송 확률 $\hat{p}_k$	기대 일수 $365\hat{p}_k$
0	47	0.1310	47.8
1	97	0.2662	97.2
2	109	0.2706	98.8
3	62	0.1834	66.9
4	25	0.0932	34.0
5	16	0.0379	13.8
6	4	0.0128	4.7
7	3	0.0037	1.4
8	2	0.0009	0.3
9+	0	0.0003	0.1

관측 도수와 기대 도수가 잘 맞아, 이 자료에는 포아송 분포가 적절함을 보여 준다.

3. 기하분포 Geometric distribution

모수 $\beta > 0$ 인 **기하분포**의 확률함수·분포함수·pgf는

$$p_k = \frac{1}{1+\beta} \left(\frac{\beta}{1+\beta} \right)^k, \quad F(k) = 1 - \left(\frac{\beta}{1+\beta} \right)^{k+1}, \quad k = 0, 1, 2, \dots \quad (7, 8)$$

$$P(z) = [1 - \beta(z - 1)]^{-1}, \quad |z| < \frac{1+\beta}{\beta} \quad (9)$$

이고 평균은 β , 분산은 $\beta(1+\beta)$ 이다. 분산이 평균보다 크다는 점에 주목하라.

4. 음이항분포 Negative binomial distribution

폴리아(Polya) 분포라고도 불리는 음이항분포는 $r, \beta > 0$ 에 대해

$$p_k = \frac{\Gamma(r+k)}{\Gamma(r)k!} \left(\frac{1}{1+\beta} \right)^r \left(\frac{\beta}{1+\beta} \right)^k, \quad k = 0, 1, 2, \dots \quad (10)$$

$$P(z) = \{1 - \beta(z - 1)\}^{-r}, \quad |z| < \frac{1+\beta}{\beta} \quad (11)$$

이다. 평균은 $r\beta$, 분산은 $r\beta(1+\beta)$ 로 **분산이 평균을 초과**한다 — 이것이 **과대산포(overdispersion)**의 전형이며, 포아송이 자료에 맞지 않을 때 음이항(과 그 특수경우인 $r=1$ 의 기하분포)이 클레임 건수 모형으로 자주 쓰이는 이유다.

독립 음이항 변수 X_i (모수 r_i, β)의 합은 모수 $r_1 + \dots + r_n, \beta$ 인 음이항이다. 따라서 r 가 크면 중심극한정리에 의해 근사적으로 정규분포다. 한편 $r\beta = \lambda$ 를 고정한 채 $r \rightarrow \infty, \beta \rightarrow 0$ 이면 극한은 평균 λ 인 포아송이다 — r 가 크고 β 가 작으면 포아송 근사가 좋다. $r=1$ 이면 기하분포, r 가 정수이면 **파스칼(Pascal) 분포**라고도 부른다.

원문 예제 2 (Tröbliger, 1961). 자동차보험의 한 등급에 속한 운전자 23,589명의 1년간 사고 건수 자료에 포아송과 음이항을 최대우도로 적합한 결과다.

표 2. 자동차 클레임 빈도의 두 모형 (원문 표 3)

건수/년	운전자 수	포아송 기대	음이항 기대
0	20592	20420.9	20596.8
1	2651	2945.1	2631.0
2	297	212.4	318.4
3	41	10.2	37.8
4	7	0.4	4.4
5	0	0.0	0.5
6	1	0.0	0.1
7+	0	0.0	0.0
계	23589	23589.0	23589.0

특히 **오른쪽 꼬리**에서 음이항이 포아송보다 훨씬 잘 맞는다 — 사고를 3건 이상 낸 운전자가 포아송 예측(약 10.6명)보다 실제(49명)로 훨씬 많은데, 음이항(42.8명)은 이를 잘 포착한다.

해설 과대산포는 왜 생기는가 — 이질성

포트폴리오의 운전자들이 저마다 다른 사고 성향 λ 를 가진다고 하자. 개인별로는 포아송이라도, λ 에 감마분포를 섞으면(혼합) 전체 건수는 정확히 음이항이 된다. 즉 "분산 > 평균"은 흔히 **위험의 이질성**의 신호다. 한국 자동차보험의 우량할인·할증(BM) 제도가 음이항(포아송-감마) 모형에 기반한 신뢰도 이론으로 설계되는 것도 같은 맥락이며, 보험계리사 시험의 빈도모형 단원에서 "표본분산/표본평균" 비로 포아송·음이항·이항을 가르는 진단이 단골로 출제된다.

예제 적률법으로 음이항 모수 구하기

표 2의 자료에서 표본평균과 표본분산을 구하고, 적률법으로 음이항 모수 $\hat{r}, \hat{\beta}$ 를 추정하라.

총 건수는 $2651+2\cdot 297+3\cdot 41+4\cdot 7+6\cdot 1 = 3402$ 이므로 평균 $\bar{x}=3402/23589=0.1442$. 또 $\sum k^2 n_k = 2651+4\cdot 297+9\cdot 41+16\cdot 7+36\cdot 1=4356$ 에서 $E[N^2]=0.1847$, 분산 $s^2=0.1847-0.1442^2=0.1639$. 적률방정식 $r\beta=0.1442$, $r\beta(1+\beta)=0.1639$ 에서 $1+\beta=0.1639/0.1442=1.137$, 즉 $\beta=0.137$, $\hat{r}=0.1442/0.137=1.05$. 분산이 평균보다 13.7% 크므로 포아송(분산=평균)으로는 부족하고, 음이항이 적절함을 수치로 확인할 수 있다. 최대우도 추정치도 이와 비슷한 값을 준다.

5. 로그분포 Logarithmic distribution

로그(로그급수)분포는 $0 < q = \beta/(1+\beta) < 1$ 에 대해

$$p_k = \frac{q^k}{-k \log(1-q)} = \frac{1}{k \log(1+\beta)} \left(\frac{\beta}{1+\beta} \right)^k, \quad k = 1, 2, 3, \dots \quad (12)$$

$$P(z) = \frac{\log(1-qz)}{\log(1-q)}, \quad |z| < \frac{1}{q} \quad (13)$$

이고 평균은 $\beta/\log(1+\beta)$, 분산은 $\{\beta(1+\beta)\log(1+\beta)-\beta^2\}/\{\log(1+\beta)\}^2$ 이다. 앞의 분포들과 달리 **0에 확률질량이 없다**($k=1$ 부터 시작). 또한 기하분포처럼 p_k 가 k 에 대해 단조 감소라는 점이 모형화에서는 제약이 된다.

로그분포는 음이항·포아송과 밀접하다. 음이항 N 에 대해 $Y=N|N>0$ (영절단)의 확률함수를 정리하면

$$p_y = \frac{\Gamma(r+y)}{\Gamma(r+1)y!} \frac{r}{(1+\beta)^r-1} \left(\frac{\beta}{1+\beta} \right)^y \rightarrow \frac{q^y}{-y \log(1-q)} \quad (r \rightarrow 0) \quad (15, 16)$$

즉 **로그분포는 영절단 음이항분포의 $r \rightarrow 0$ 극한**이다. (한편 복합 포아송-로그 분포가 정확히 음이항이 된다는 사실은 "복합 포아송 빈도모형" 표제어에서 다룬다.)

6. 이항분포 Binomial distribution

앞의 분포들과 달리 **유한한 받침** $\{0, 1, \dots, n\}$ 을 갖는 이항분포는 $0 < p < 1$ 에 대해

$$p_k = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \dots, n; \quad P(z) = \{1 + p(z-1)\}^n \quad (17)$$

이다(평균 np , 분산 $np(1-p)$) — **분산이 평균보다 작은 과소산포**. n 이 크고 $np=\lambda$ 이면 포아송으로 잘 근사되며, 계산 편의 때문에도 포아송 근사가 즐겨 쓰인다. $n=1$ 이면 **베르누이 분포**다.

심화 해설 세 분포는 한 가족 — (a, b, 0)족

포아송·음이항(기하 포함)·이항은 모두 $p_k/p_{k-1} = a + b/k$ 라는 공통 재귀를 만족하는 **(a, b, 0)족**이다 ($a < 0$: 이항, $a=0$: 포아송, $0 < a < 1$: 음이항). 이 구조 덕분에 총클레임 분포를 효율적으로 계산하는 **판여 (Panjer) 재귀**가 성립하며, 분산/평균 비(1보다 작음·같음·큼)로 셋 중 하나를 고르는 실무 진단과도 정확히 대응한다. 자세한 내용은 "Sundt and Jewell Class of Distributions" 표제어를 보라.

7. 일반화 Generalizations

위 분포들의 일반화는 무수히 많으며, 대표적 두 방법이 **혼합(mixing)**과 **복합(compounding)**이다. 혼합분포와 복합분포는 이 백과사전의 다른 표제어에서 다룬다. 예컨대 **들라포르트(Delaporte) 분포**는 포아송과 음이항을 혼합해 얻는다. 그 밖의 기법에 의한 일반화 이산분포 역시 별도 표제어("일반화 이산분포")의 주제다. 이산분포 전반의 포괄적 문헌으로는 Johnson, Kotz & Kemp의 Univariate Discrete Distributions가 있다.

참고 및 관련 표제어

관련 표제어. Approximating the Aggregate Claims Distribution(총클레임분포의 근사) · Collective Risk Models(집합위험모형) · Compound Poisson Frequency Models(복합 포아송 빈도모형) · Discrete Multivariate Distributions(이산 다변량분포) · Discretization of Distributions(분포의 이산화) · Failure Rate(고장률) · Mixed Poisson Distributions(혼합 포아송 분포) · Mixture of Distributions(혼합분포) · Sundt and Jewell Class of Distributions(순트-주얼 분포족) · Thinned Distributions(희석분포)

원문 참고문헌(발췌). Douglas, Analysis with Standard Contagious Distributions (1980) · Tröbliger, Blätter der DGVM 5 (1961) 327-348 · Johnson, Kotz & Kemp, Univariate Discrete Distributions, 2nd ed. (Wiley, 1992) · Rolski, Schmidli, Schmidt & Teugels, Stochastic Processes for Insurance and Finance (Wiley, 1999)

부록. 이 글에 나온 용어 (배경지식 보충)

- **계수분포 (counting distribution)** — 0, 1, 2, ...에만 확률이 놓이는 이산분포. 클레임 건수 모형의 기본 틀.
- **확률생성함수 (pgf)** — $E[z^N]$. 분포를 유일하게 결정하며 독립합·합성·적률 계산의 핵심 도구.
- **재생성 (reproducibility)** — 같은 족의 독립합이 다시 같은 족이 되는 성질. 포아송·음이항(β 공통)이 가진다.
- **무한분해가능 (infinitely divisible)** — 임의의 n 에 대해 iid n 개의 합으로 표현 가능한 분포. 레비 과정과 연결된다.
- **과대산포 (overdispersion)** — 분산 > 평균. 위험 이질성의 신호로, 음이항의 영역.
- **영절단 분포 (zero-truncated)** — $N|N>0$. 0건은 관측되지 않는 자료(접수된 클레임만 기록)에 자연스럽다.
- **최대우도 추정 (MLE)** — 관측자료의 우도를 최대화하는 모수값. 포아송에서는 표본평균과 일치.
- **적률법 (method of moments)** — 표본적률 = 이론적률 방정식으로 모수를 푸는 추정법.
- **혼합 (mixing)** — 모수에 분포를 입혀 평균화하는 일반화. 포아송-감마 혼합 = 음이항.
- **복합 (compounding)** — 랜덤 횟수의 합 $N_1 + \dots + N_M$ 꼴 일반화. 포아송-로그 복합 = 음이항.
- **들라포르트 분포 (Delaporte)** — 포아송 성분과 음이항 성분의 합(혼합)으로 얻는 3모수 계수분포.
- **파스칼 분포 (Pascal)** — r 가 정수인 음이항분포의 별칭.

원문: Encyclopedia of Actuarial Science (Wiley, 2004), "Discrete Parametric Distributions", Harry H. Panjer. · 본 해설서의 [해설]·[예제]·[부록]은 학부 입문 학습용으로 추가·구성한 것임. 수식은 원문 기준 복원.