

일반화 선형모형 (Generalized Linear Models)

출처: Encyclopedia of Actuarial Science (Wiley, 2004)

읽는 법. 본문은 원문 표제어의 내용을 그대로 옮긴 것입니다. 회색 **해설** · **예제** 상자는 학부 입문 학습을 돕기 위해 새로 추가한 부분이며, 원문에는 없습니다. 처음 보는 용어는 글 끝 **부록(보험·통계 용어 풀이)**을 참고하세요.

※ 원문은 11쪽 분량의 개관 논문입니다. 이 해설서는 핵심을 간추린 요약본입니다.

1. 왜 GLM인가 — 보통 회귀의 한계 Why GLM?

계량경제 실무에서 가장 널리 쓰이는 통계기법은 다중 선형회귀다. 그러나 보험계리 통계가 다루는 상황은 이 틀에 잘 맞지 않는다. 회귀분석은 오차가 **정규분포**를 따르고, **분산이 일정**하며, 평균이 설명변수에 대해 **선형(가법적)**이라고 가정한다. 그런데 —

- 클레임 건수는 포아송 분포가 적절한데, 실제 자료는 분산이 평균보다 큰 **과산포**를 보이는 일이 많다.
- 클레임 금액의 분포는 오른쪽 꼬리가 두꺼워야 하고, 분산이 일정하기보다는 **변동계수(σ/μ)**가 일정한 쪽이 자연스럽다.
- 현상이 설명변수에 대해 가법적인 경우는 드물다. 포트폴리오가 10% 커지면 클레임도 (일정액이 아니라) **10% 더** 나야 하므로, 준비금 산정 등에서는 **곱셈 모형**이 훨씬 그럴듯하다.

한 가지 우회로는 관측값을 변환해 보통 회귀에 맞추는 것이다. 포아송 변수 Y 라면 $Y^{2/3}$ 은 왜도를 거의 0으로, $Y^{1/2}$ 은 분산을 안정화하고, $\log Y$ 는 곱셈적 효과를 가법적으로 바꾼다. 그러나 세 가지를 동시에 만족시키는 변환은 없고, 변환된 척도에서 성립하던 불편성·일치성이 원래 척도로 되돌리면 깨질 수 있다. 이 문제들을 한꺼번에 해결하는 틀이 **일반화 선형모형(GLM)**이다. 일반화는 두 방향이다. 첫째, 평균 둘레의 확률적 변동이 정규분포가 아니어도 된다 — **지수산포족**(정규·포아송·(음)이항·감마·역가우스 포함)이면 충분하다. 둘째, 평균이 설명변수의 선형함수일 필요가 없고, **어떤 척도(링크) 위에서만 선형**이면 된다. 척도가 로그라면 곱셈 모형이 된다. GLM은 Nelder & Wedderburn(1972)이 도입했고, 통계 패키지(GLIM, SAS GenMod, S-Plus/R)로 널리 구현되어 있다. 분산분석(ANOVA), 포아송 회귀, 로짓·프로빗 모형이 모두 GLM의 특수경우이며, 베일리-사이먼 요율산정법 같은 전통적 보험계리 기법들도 사실은 특정 GLM의 최대우도 추정과 동치임이 알려져 있다.

해설 GLM은 요율산정의 세계 표준

오늘날 자동차보험·실손보험의 요율 세분화(연령×차종×지역×할인할증...)는 거의 예외 없이 GLM으로 이루어진다. 한국 손해보험 실무에서도 빈도는 포아송(로그 링크), 심도는 감마(로그 링크)로 적합하는 "빈도×심도 GLM"이 표준이고, 계리사 시험의 손해보험 수리 과목에서도 핵심 주제다. 이 표제어(원저자 Rob

Kaas)는 GLM의 일반론에 더해, 지급준비금(IBNR) 삼각형의 체인래더법이 사실 포아송 GLM이라는 점을 중심으로 설명한다.

2. GLM의 정의 — 세 가지 구성요소 Definition

(1) **확률적 성분**. 관측값 $Y_1, \dots, Y_n$ 은 독립이고, 각 밀도는 **지수산포족(exponential dispersion family)**에 속한다:

$$f_Y(y; \theta, \psi) = \exp\left(\frac{y\theta - b(\theta)}{\psi} + c(y; \psi)\right), \quad y \in D_\psi \quad (1)$$

모수 θ 는 평균과 연결되고, ψ 는 평균에는 영향을 주지 않으면서 분산을 $\psi V(\mu)$ 꼴로 만든다. $b(\theta)$ 는 **누울함수(cumulant function)**라 불리는데, Y 의 누울이 $\kappa_j(Y) = b^{(j)}(\theta)\psi^{j-1}$ 을 만족하기 때문이다. 특히

$$E[Y] = \mu = b'(\theta), \quad \text{Var}[Y] = b''(\theta)\psi, \quad V(\mu) = b''(\theta(\mu))$$

이고 $V(\cdot)$ 를 **분산함수**라 한다. 보통 $\psi_i = \phi/w_i$ 로 두는데, ϕ 는 **산포모수(dispersion parameter)**, w_i 는 관측 i 의 가중치(그 관측이 몇 개의 i.i.d. 관측의 평균인지)다. 보험계리에서 중요한 구성원과 분산함수는 다음과 같다(μ 의 거듭제곱이 커지는 순서).

지수산포족의 주요 구성원 ($w=1$, $\sigma^2 = V(\mu)\phi$)

분포	분산함수 $V(\mu)$	분산 σ^2	특징
정규 $N(\mu, \psi)$	$\mu^0=1$	ϕ (등분산)	고전 회귀
포아송(μ)	μ	μ	분산=평균
포아송 배수 $\psi \times$ 포아송(μ/ψ)	μ	$\mu\phi$	과산포 포아송 ($\phi>1$)
$\psi \times$ 이항($1/\psi, \mu$)	$\mu(1-\mu)$	—	$1/\psi$ 회 시행의 성공비율
감마($1/\psi, 1/(\psi\mu)$)	μ^2	$\mu^2\phi$	변동계수 일정
역가우스	μ^3	$\mu^3\phi$	더 두꺼운 꼬리

분산은 관측의 **정밀도**를 말해 준다. 포아송에서는 값이 큰 관측일수록 허용되는 적합 오차가 크고, 감마·역가우스는 그 경향이 더 강하다.

(2) **체계적 성분**. 각 관측에 설명변수의 선형결합인 **선형예측자(linear predictor)**를 부여한다:

$$\eta_i = \sum_{j=1}^p x_{ij} \beta_j$$

(3) **링크함수**. 평균 μ_i 와 선형예측자 η_i 를 매끄러운 가역함수 g 로 잇는다:

$$\eta_i = g(\mu_i)$$

각 분포에는 기술적 장점이 있는 **정준 링크(canonical link)**가 있다 — 정규는 항등(가법 모형), 포아송은 로그(곱셈·로그선형 모형), 감마는 역수다.

심화 해설 "선형모형"의 두 끝 — 영모형과 포화모형

가장 거친 모형은 상수항만 쓰는 **영모형(null model)**으로, 모든 변동을 우연으로 돌리고 전체 (가중)평균 하나로 모든 μ_i 를 추정한다. 반대 극단인 **포화모형(full model)**은 관측마다 모수를 하나씩 두어 $\hat{\mu}_i = y_i$ 가 된다 — 자료를 그대로 반복할 뿐 아무 구조도 부여하지 않는다. 좋은 모형은 그 사이 어딘가에 있다. 적합도(예측력)와 간결성(관리가능성) 사이의 트레이드오프가 모형선택의 본질이다.

3. 이탈도와 잔차 — 모형의 품질 평가 Deviance and residuals

GLM에서 모형 품질의 기준은 로그우도에 기초한 (**척도화**) **이탈도(scaled deviance)**다. 어떤 모형 세분화가 실제 개선이 아니라는 귀무가설 아래에서, 로그우도 증가분의 -2 배는 근사적으로 (추가 추정 모수 개수를 자유도로 갖는) χ^2 분포를 따른다. 척도화 이탈도는 두 모형의 우도비 로그의 -2 배이고, 이탈도는 여기에 산포모수 ϕ 를 곱한 것이다. 포화모형의 로그우도가 기준점(yardstick) 역할을 하며, 두 중첩 모형의 이탈도 차는 각 모형의 포화모형 대비 이탈도의 차로 계산된다(이런 의미에서 이탈도는 가법적이다). 비교하는 모형들은 (재모수화 후) 모수집합이 중첩되어야 할 뿐 아니라 **링크함수와 오차분포가 같아야** 한다.

모형이 충분히 좋은지, 어디를 개선해야 하는지는 **잔차** — 관측값과 적합값의 차이를 분산함수로 표준화한 것 —로 살핀다. 보통의 **피어슨 잔차**도 쓰지만 GLM에서는 각 관측의 최대 로그우도 기여분에 기초한 **이탈도 잔차(deviance residual)**가 선호된다. 정규분포·항등링크에서는 표준화 잔차 제곱합이 χ^2 분포를 따르고 최대우도 차이에 비례하며, 다른 분포에서는 이 양이 적합도 비교의 대안이 된다.

4. 한계총합 방정식과 포아송 최대우도 Marginal totals

보험료 산정의 건전한 방법 중 하나가 **한계총합법(method of marginal totals)**이다. 발상은 수지상등 원리와 같다 — 좋은 요율체계라면 **충분히 큰 위험집단별로 보험료 총액과 관측 손해액이 일치**해야 한다. 곱셈 모형 $X_{ij} \approx \alpha_i \beta_j$ 에서 행(i) 또는 열(j)이 같은 집단마다 이 조건을 요구하면, 미지수만큼의 방정식으로 이루어진 **한계총합 방정식**을 얻는다:

$$\sum_i w_{ij} \alpha_i \beta_j = \sum_i w_{ij} y_{ij} \quad (\forall j), \quad \sum_j w_{ij} \alpha_i \beta_j = \sum_j w_{ij} y_{ij} \quad (\forall i) \quad (2)$$

행 총합이 모두 맞으면 전체 총합도 맞으므로 방정식 하나는 잉여이고, 이는 α, β 가 곱셈 상수 하나만큼 미정인 것과 대응한다. X_{ij} 가 클레임 건수라면 더 깊은 해석이 있다. 셀 (i,j)의 피보험자 w_{ij} 명 각각의 건수가 포아송(λ_{ij}), $\lambda_{ij} = \alpha_i \beta_j$ 라 하자. 관측 건수 s_{ij} 에 대한 우도

$$L = \prod_{i,j} e^{-w_{ij} \lambda_{ij}} \frac{(w_{ij} \lambda_{ij})^{s_{ij}}}{s_{ij}!} \quad (3)$$

에 $\lambda_{ij}=\alpha_i\beta_j$ 를 대입해 $\log L$ 을 α_i, β_j 로 최대화하면 정확히 식 (2)가 나온다. 즉 **한계총합법 = 포아송 최대우도**이고, 행합·열합이 충분통계량이다. 최대우도 방정식의 수치해는 뉴턴-랩슨 반복

$$x_{t+1} = x_t - (f'(x_t))^{-1}f(x_t) \quad (4)$$

의 다차원 버전(헤시안 행렬 필요)으로 구하는데, Nelder-Wedderburn 알고리즘은 헤시안 대신 그 기댓값인 **정보행렬**을 쓴다(**피셔 득점법**). 이 반복 한 단계는 가중회귀 문제를 푸는 것과 같다.

예제 1 2×2 곱셈 모델을 한계총합으로 풀기

두 연령군(행)×두 지역(열) 포트폴리오에서 관측 클레임 건수가 $y_{11}=20, y_{12}=40, y_{21}=30, y_{22}=90$ (모든 셀 $w=1$)이다. 곱셈 모델 $E[X_{ij}]=\alpha_i\beta_j$ ($\beta_1+\beta_2=1$ 로 정규화)를 한계총합법으로 적합하라.

행합 $R_1=60, R_2=120$, 열합 $K_1=50, K_2=130$, 총합 180. 행 방정식 $\alpha_i(\beta_1+\beta_2)=R_i$ 에서 $\alpha_1=60, \alpha_2=120$. 열 방정식 $(\alpha_1+\alpha_2)\beta_j=K_j$ 에서 $\beta_1=50/180=0.278, \beta_2=130/180=0.722$. 적합값은

$$\hat{X}_{11} = 60 \times 0.278 = 16.7, \hat{X}_{12} = 43.3, \hat{X}_{21} = 33.3, \hat{X}_{22} = 86.7$$

행합·열합이 관측치와 정확히 일치함을 확인할 수 있다($16.7+43.3=60$ 등). 이것이 로그 링크 포아송 GLM의 최대우도 적합값이기도 하다. 셀별로는 어긋나도(20 vs 16.7) 한 단계 높은 집계 수준에서는 수치가 맞는다 — 요율산정에서 "공정한 분류요율"의 의미다.

5. GLM과 지급준비금 — 런오프 삼각형의 3요인 모형 Reserving

IBNR(발생했으나 미보고된 클레임) 준비금은 보통 **런오프 삼각형**으로 추정한다. 행은 사고연도(year of origin) i , 열은 진전연도(development year) j 이고, X_{ij} 는 그 조합의 지급액(달력연도 $k=i+j-1$ 에 지급됨)이다. 세 시간 축은 각각 다른 외생요인을 반영한다 — 사고연도 방향은 **포트폴리오 규모**의 변화, 진전연도 방향은 **클레임 처리·종결 속도**의 변화, 대각선(달력연도) 방향은 **인플레이션**·판례 변경·청구성향 증가다. 이를 모두 담는 곱셈 3요인 모형이

$$X_{ij} \approx \alpha_i \beta_j \gamma_k, \quad k = i + j - 1 \quad (5)$$

이다. 행·열·대각선 더미변수를 도입하면 $E[X_{ij}]=\exp(\log \alpha_i + \log \beta_j + \log \gamma_k)$ 인 **로그 링크 GLM**이 된다. 모수를 추정한 뒤 $\hat{X}_{ij}=\hat{\alpha}_i\hat{\beta}_j\hat{\gamma}_k$ 로 삼각형을 사각형으로 완성하면, 미래 지급액 예측치의 총합이 준비금이 된다(미래 달력연도의 γ_k 는 $\gamma_k \propto \gamma^k$ 같은 기하적 외삽으로 보충). 분포 가정에 따라 다음의 전통적 기법들이 그대로 재현된다.

- **체인래더(chain-ladder)** — $\gamma_k \equiv 1, X_{ij} \sim$ 포아송($\alpha_i\beta_j$) 독립. "어느 사고연도든 진전연도별 종결 비율이 같다(열이 비례한다)"는 발상이다.
- **산술 분리법(arithmetic separation)** — $\alpha_i \equiv 1, X_{ij} \sim$ 포아송($\beta_j\gamma_k$) 독립. 진전 패턴과 달력연도(인플레이션) 효과로 설명하며, Verbeek(1972)이 처음 기술했다.
- **기하 분리법(geometric separation)** — $\log X_{ij} \sim N(\log(\beta_j\gamma_k), \sigma^2)$ 독립. 이때 $\beta_j\gamma_k$ 는 평균이 아니라 **중앙값**이다($E[X_{ij}]=e^{\sigma^2/2}\beta_j\gamma_k$).

- 드 페일더르 최소제곱법(De Vijlder) — $x_k \equiv 1, \sum (X_{ij} - \alpha_i \beta_j)^2$ 최소화. $X_{ij} \sim N(\alpha_i \beta_j, \sigma^2)$ 의 최대우도와 같다.

체인래더 = 포아송 GLM의 풀이. $\beta_1 + \dots + \beta_t = 1$ 로 정규화하면 β_j 는 진전연도 j의 종결 비율, α_i 는 사고연도 i의 총규모(volume)로 해석된다. §4에서 본 대로 최대우도 추정치는 한계총합(행합 R_i , 열합 K_j) 방정식을 만족하고, 삼각형의 특수한 모양 덕분에 다음과 같이 차례로 풀린다: $\hat{\alpha}_1 = R_1$ 에서 시작해, $\hat{\alpha}_t \beta_t = K_t$ 로 β_t 를 얻고,

$$\hat{\alpha}_{t-n+1}(\hat{\beta}_1 + \dots + \hat{\beta}_n) = R_{t-n+1}, \quad (\hat{\alpha}_1 + \dots + \hat{\alpha}_{t-n+1})\hat{\beta}_n = K_n \quad (6, 7)$$

을 $n=t-1, t-2, \dots, 1$ 에 대해 반복한다. 이렇게 얻은 예측은 잘 알려진 체인래더 절차(관측 열합·행합의 비율 곱)와 정확히 일치하며, 삼각형을 대각선에 대해 뒤집어도(사고연도↔진전연도 교환) 같은 결과를 준다. 즉 **전통적 체인래더 계산은 독립 포아송($\alpha_i \beta_j$) 모형의 ML 추정 알고리즘**이다. Mack(1993)은 거꾸로 우도를 명시하지 않는 분포-자유(distribution-free) 최소가정 아래에서 같은 계산을 정당화하고 최소분산 불편추정을 추구했다.

6. 수치 사례 — 모형 선택과 이탈도 분석 Worked example

원문은 2000~2007년 8개 사고연도의 지급 건수 런오프 삼각형(Kaas et al. 2001의 예)에 여러 모형을 적용한다. 모두 $X_{ij} \sim \text{포아송}(\alpha_i \beta_j x_{i+j-1})$ 을 바탕으로 $\beta_j = \beta^{j-1}$, $x_k \equiv 1$ 같은 제약을 가해 축소한 모형들이다. 주요 결과:

모형별 모수·자유도·이탈도 (원문 Table 5 발췌)

모형	모수	자유도	이탈도	평가
I	$\mu, \alpha_i, \beta_j, x_k$	15	25.7	가장 풍부, 최선의 적합
II (체인래더)	μ, α_i, β_j	21	38.0	I 대비 기각 안 됨 ($\Delta=12.3 < \chi^2_6=12.6$)
III (산술분리)	μ, β_j, x_k	21	36.8	II와 비슷한 적합
VIII	$\mu, \alpha_i, \beta_i, \beta^{j-1}$	26	46.0	승자 — 모수 5개 적는데 II 대비 유의한 악화 없음
IX	$\mu, \alpha^{i-1}, \beta_i, \beta^{j-1}$	32	67.9	모수 4개로 이탈도의 97.4% 설명
XI (영모형)	μ	35	2656	기준점

모형 VIII은 "첫 진전연도만 따로 두고 이후는 기하적 진전 패턴"을 가정한 것으로, 추정 결과는

$$\hat{X}_{ij} = 102.3 \times \hat{\alpha}_i \times 3.20^{j-1} \times 0.42^{j-1}$$

꼴이다($j \neq 1$ 은 불리언: 첫 열만 예외 취급). 완성된 사각형에서 사고연도별 미래 지급 예측 합계(준비금)는 2001년 0.8건부터 2007년 398.7건까지, 총 696.8건이다. 모형 VIII의 "설명된 이탈도 비율"은 98%가 넘는다. 과모수화를 피하는 요령으로 원문은 — 모수 다수를 1로 고정하기, 인접 계급 묶기, 순서 있는 분류(연령, 할인할증 등급)는 더미 대신 **변량(variate)**으로 취급해 기하적 진행 α^{i-1} , β^{j-1} 로 대체하기, 특정 달력연도의 이상 인플레이션은 별도 더미로 처리하기 — 를 제시한다. 다만 세 시간 효과를 모두 기하적으로 두면 모수 간 종속("더미 함정", 다중공선성)이 생기므로 하나는 1로 고정해야 한다.

준비금 예측치의 분산 추정은 예측구간 제시를 위해 실무적으로 매우 중요하다. 모형과 모수가 맞다면 분산은 **모수 불확실성**과 **과정 변동성**의 합으로 구성된다. 위 예에서 모수를 참값으로 간주하면 연도별 합계는 독립 포아송이므로 과정분산 = 평균 = 696.8, 즉 표준편차 약 26.4건이다. 과산포가 있으면 추정 과산포계수를 곱해야 하고, 실제로는 추정평균의 변동까지 더해야 한다. 빈도(건수)에는 체인래더(포아송, 사고연도×진전연도)가 적절하지만, **클레임 금액**에는 포트폴리오 규모 α_i 가 무의미한 대신 인플레이션(달러연도)이 중요하므로 분리법이 더 알맞다는 것이 원문의 결론이다.

참고 및 관련 표제어

관련 표제어. Bailey-Simon Method(베일리-사이먼 방법) · Regression Models for Data Analysis(자료분석을 위한 회귀모형) · Reserving in Non-life Insurance(손해보험 지급준비금) · Discrete Parametric Distributions(이산 모수분포) · Continuous Parametric Distributions(연속 모수분포) · Maximum Likelihood(최대우도) · Compound Poisson Frequency Models(복합 포아송 빈도모형) · Bonus-Malus Systems(할인할증제도)

원문 참고문헌(발췌). Nelder & Wedderburn, JRSS A 135 (1972) · McCullagh & Nelder, Generalized Linear Models (Chapman & Hall, 1989) · Kaas, Goovaerts, Dhaene & Denuit, Modern Actuarial Risk Theory (Kluwer, 2001) · Taylor, Claims Reserving in Non-Life Insurance (North Holland, 1986) · England & Verrall, BAJ 8 (2002) · Verbeek, ASTIN Bulletin 6 (1972) · Mack, ASTIN Bulletin 23 (1993) · Doray, IME 18 (1996).

부록. 이 글에 나온 용어 (배경지식 보충)

- **지수산포족 (exponential dispersion family)** — 밀도가 $\exp\{(y\theta - b(\theta))/\psi + c(y;\psi)\}$ 꼴인 분포족. GLM의 오차 분포 후보.
- **링크함수 (link function)** — 평균 μ 와 선형예측자 η 를 잇는 가역함수 $g: \eta = g(\mu)$. 로그 링크면 곱셈 모형.
- **정준 링크 (canonical link)** — $\theta = \eta$ 가 되게 하는 링크. 정규=항등, 포아송=로그, 감마=역수.
- **산포모수 ϕ (dispersion parameter)** — 평균과 무관하게 분산 크기를 조절하는 모수. 과산포 포아송에서 $\phi > 1$.
- **이탈도 (deviance)** — 포화모형 대비 우도비 로그의 -2 배($\times \phi$). 중첩 모형 비교의 χ^2 통계량.
- **런오프 삼각형 (run-off triangle)** — 사고연도×진전연도로 집계한 지급액 표. 준비금 추정의 기본 자료.
- **체인래더 (chain-ladder)** — 열들이 비례한다고 보고 삼각형을 완성하는 고전 기법. 포아송 GLM의 ML과 동치.
- **분리법 (separation method)** — 진전연도×달러연도 효과로 설명하는 준비금 기법. 인플레이션 반영에 유리.
- **IBNR** — 발생했으나 아직 보고되지 않은 클레임(incurring but not reported). 이를 위한 준비금이 IBNR 준비금.
- **충분통계량 (sufficient statistic)** — 모수 추정에 필요한 정보를 모두 담은 통계량. 포아송 곱셈모형에서는 행·열합.
- **피셔 득점법 (Fisher scoring)** — 뉴턴-랩슨에서 헤시안 대신 정보행렬을 쓰는 ML 알고리즘. 가중회귀 반복과 동치.

- **더미 함정 (dummy trap)** — 더미변수들이 선형종속이 되는 다중공선성 문제. 기준 수준 고정으로 해결.

원문: Encyclopedia of Actuarial Science (Wiley, 2004), “Generalized Linear Models”, Rob Kaas. · 본 해설서의 [해설]·[예제]·[부록]은 학부 입문 학습용으로 추가·구성한 것임. 수식은 원문 기준 복원.