

재표본추출 (Resampling)

출처: Encyclopedia of Actuarial Science (Wiley, 2004)

읽는 법. 본문은 원문 표제어의 내용을 그대로 옮긴 것입니다. 회색 **해설** · **예제** 상자는 학부 입문 학습을 돕기 위해 새로 추가한 부분이며, 원문에는 없습니다. 처음 보는 용어는 글 끝 **부록(보험·통계 용어 풀이)**을 참고하세요.

1. 배경 — 왜 재표본추출인가 Background

재표본추출(resampling) 방법은 컴퓨터 성능의 증가 덕분에 통계학에서 인기를 얻었다. 얼마 전까지 대부분의 통계 연구는 필요한 공식을 종이와 연필로 유도하는 **해석적 방법**을 썼지만, 컴퓨터는 그 대신 재표본추출을 포함한 **시뮬레이션 방법**을 가능하게 했다(베이즈 통계에서 MCMC의 등장과 비슷한 흐름이다). 재표본추출은 신뢰구간, 분위수 추정, 가설검정, 편향 평가 등 매우 넓은 영역에서 쓰인다.

독립 관측 표본 $x_1, x_2, \dots, x_n$ 이 있고, 모수 θ 의 추정량 $\hat{\theta}$ 의 **표집분포(sampling distribution)**가 필요하다고 하자. 정공법은 자료 분포를 가정(예: 정규)하고 분포를 직접 유도하는 것이지만, 그것이 어려울 때의 대안이 시뮬레이션 — 특히 **표본 자신에서 값을 다시 뽑는** 방법이다. 통계량의 분포를 "재표본추출된" 분포로, 모수의 참값을 표본 값으로 대체하는 것이 기본 아이디어다.

2. 잭나이프 The jackknife

최초의 재표본추출형 방법은 **잭나이프**(Quenouille 1956)다. 원표본에서 관측값을 하나씩 빼서 $n-1$ 개짜리 표본 n 개를 만든다. i 번째 잭나이프 표본은

$$x_{(i)} = (x_1, x_2, \dots, x_{i-1}, x_{i+1}, \dots, x_n)$$

이고, 이 n 개 표본으로 추정량 $\hat{\theta}$ 의 성질을 조사한다. 예컨대 **편향의 잭나이프 추정**은

$$\widehat{bias} = (n-1) \left(\frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(i)} - \hat{\theta} \right)$$

이다($\hat{\theta}_{(i)}$ 는 i 를 뺀 표본의 추정값). 잭나이프는 보험계리 문헌에서는 많이 쓰이지 않았다(Ashe 1986, Taylor 1988이 예외).

3. 붓스트랩 The bootstrap

더 중요한 것은 **붓스트랩**(Efron 1979)으로, 근래 보험계리 문헌 일부 영역에서 인기를 얻기 시작했다. 잭나이프 처럼 원자료에서 값을 재추출해 의사자료(pseudo-data) 표본을 만들지만, 방식이 다르다 — **자료에서 복원추출로 무작위 표본을 뽑는다**. 절차는:

- $x_1, \dots, x_n$ 에서 복원추출한 n 개 값으로 붓스트랩 표본 x^* 를 만든다.
- 이를 B 번 반복해 $x^{*1}, x^{*2}, \dots, x^{*B}$ 를 얻고, 각각에서 관심 통계량 θ^{*b} 를 계산한다.
- $\theta^{*1}, \dots, \theta^{*B}$ 의 경험분포에서 통계량의 성질(표준오차, 분위수, 신뢰구간 등)을 추정한다.

예컨대 추정량 θ 의 **표준오차의 붓스트랩 추정**은 붓스트랩 복제값들의 표본 표준편차다:

$$\widehat{se}_{boot} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B \left(\hat{\theta}^{*b} - \frac{1}{B} \sum_{b'=1}^B \hat{\theta}^{*b'} \right)^2}$$

예제 손으로 따라가는 미니 붓스트랩

클레임 3건 {1, 2, 6}(백만 원)에서 평균 손해액 $\theta = \bar{x} = 3$ 의 표준오차를 붓스트랩으로 추정해 보자. $B=5$ 회의 복원추출 결과가 (1,2,6), (2,6,6), (1,1,2), (6,2,1), (2,2,6)이라 하자.

$$\hat{\theta}^* = 3.00, 4.67, 1.33, 3.00, 3.33 \quad \bar{\theta}^* = 3.07$$

편차 제곱합 = $(-0.07)^2 + (1.60)^2 + (-1.74)^2 + (-0.07)^2 + (0.26)^2 \approx 5.66$ 이므로 $se \approx \sqrt{(5.66/4)} \approx 1.19$. 해석적 공식 $s/\sqrt{n} = 2.65/\sqrt{3} \approx 1.53$ 과 같은 차원의 답을, 분포 가정 없이 얻었다. 실전에서는 $B=1,000 \sim 10,000$ 을 쓰며, 표준오차뿐 아니라 θ^* 의 2.5%·97.5% 분위수로 **백분위수 신뢰구간**도 바로 만들 수 있다.

4. 회귀형 문제 — 잔차를 붓스트랩한다 Bootstrapping residuals

보험계리 응용은 대부분 회귀형 문제이므로, 자료 자체가 아니라 **(적절히 정의한) 잔차를 붓스트랩**하는 것이 보통이다. 정규 오차 선형회귀라면 잔차는 단순히 관측값-적합값이다. 계리 응용은 일반화 선형모형(GLM)을 더 자주 쓰므로 **이탈도(Deviance)·피어슨(Pearson)·앤스컴(Anscombe) 잔차**처럼 정규이론 잔차의 성질을 (근사적으로) 갖는 잔차를 쓴다. 절차는:

- 모형을 적합하고 잔차를 계산한다.
- 잔차에서 복원추출한 뒤, **잔차 공식을 역산(invert)**해 붓스트랩 자료 표본을 만든다.
- 모형을 다시 적합하고 관심 통계량을 계산한다.
- 이를 충분히 여러 번 반복해 통계량의 표집 성질을 조사한다.

5. 응용 — 클레임 준비금의 예측오차 Claims reserving

붓스트랩의 힘을 보여 주는 응용이 **클레임 준비금(claims reserving)**이다. 준비금 추정치의 예측오차를 해석적으로 구하는 일은 꽤 복잡해 통계 패키지의 신중한 프로그래밍이 필요하지만(England & Verrall 2002), 붓스트랩은 **체인래더 기법에 스프레드시트만으로** 적용할 수 있다 — 체인래더를 적합해 잔차를 얻고, 이를 재추출·역산해 의사 클레임 삼각형을 만들고, 다시 체인래더를 적용해 붓스트랩 준비금 추정치를 얻는다. 반복하면 준비금 추정치의 붓스트랩 분포가 나온다.

다만 주의할 점이 많다. 붓스트랩 표준오차는 추정분산의 제곱근의 추정치인데, **모형 적합에 쓰인 모수 개수를 감안하지 않으므로** 해석적 결과와 직접 비교할 수 없다 — 산포모수를 자유도가 아니라 자료 개수로 나눠 계산한 것과 같은 상태다. 제대로 비교하려면 모수 개수를 반영하는 보정을 붓스트랩 추정분산에 가해야 한다.

해설 왜 실무가 붓스트랩을 좋아하나

보험부채의 "최선추정 ± 불확실성"을 요구하는 현행 감독체계(한국의 K-ICS, 유럽 Solvency II)에서 준비금의 **분포 전체**가 필요해졌다. 해석적 공식(Mack 공식 등)은 평균·분산까지만 주지만, 붓스트랩은 준비금의 시뮬레이션 분포를 통째로 주므로 75% 분위수나 99.5% VaR 같은 양을 바로 읽을 수 있다. 영국 GISG 계열 문헌(England-Verrall)의 "과산포 포아송 체인래더 + 피어슨 잔차 붓스트랩 + 과정분산 재추가" 절차가 사실상의 업계 표준 레시피다.

심화 해설 잭나이프 vs 붓스트랩

잭나이프는 표본 n 개로 만들 수 있는 재표본이 n 개로 고정되고(결정론적), 매끄럽지 않은 통계량(중앙값 등)에서는 실패할 수 있다. 붓스트랩은 재표본 공간이 훨씬 풍부해(복원추출) 분포 전체를 근사하며, 잭나이프는 붓스트랩 분산의 선형 근사로 해석된다(Efron 1979의 논문 제목이 "another look at the jackknife"다). 비용은 계산량 — 그러나 오늘날에는 문제가 되지 않는다.

Derrig, Ostaszewski & Rempala(2000)가 보험계리에서의 붓스트랩을 개관한다. 계리 문헌의 응용 분야로는 클레임 준비금(England-Verrall, Taylor, Lowe, Kirschner 등), 파산 문제(Frees 1986; Hipp 1989), 금융(장기 수익률 — Carriere 1999; 효율적 투자선 — Scheel et al. 2001), 극단값 이론(모수 불확실성 — Mata 2000) 등이 있다.

참고 및 관련 표제어

관련 표제어. Estimation(추정) · Logistic Regression Model(로지스틱 회귀모형) · Nonparametric Statistics(비모수 통계) · Generalized Linear Models(일반화 선형모형) · Reserving in Non-life Insurance(손해보험 지급준비금)

원문 참고문헌(발췌). Efron, Annals of Statistics 7 (1979) · Efron & Tibshirani, An Introduction to the Bootstrap (Chapman & Hall, 1993) · Quenouille, Biometrika 43 (1956) · Davison & Hinkley, Bootstrap Methods and their Application (CUP, 1997) · England & Verrall, British Actuarial Journal 8 (2002) · Derrig, Ostaszewski & Rempala, PCAS (2000) · Hipp, ASTIN Bulletin 19 (1989) · Shao & Tu, The Jackknife and the Bootstrap (Springer, 1995).

부록. 이 글에 나온 용어 (배경지식 보충)

- **표집분포 (sampling distribution)** — 표본을 반복 추출했을 때 통계량이 갖는 분포. 표준오차·신뢰구간의 원천.
- **복원추출 (sampling with replacement)** — 뽑은 값을 되돌려 놓고 다시 뽑는 방식. 같은 관측이 여러 번 뽑힐 수 있다.
- **의사자료 (pseudo-data)** — 재표본추출로 만들어 낸 인공 표본. 원자료의 경험분포에서 나온 것으로 취급한다.
- **편향 (bias)** — $E[\hat{\theta}] - \theta$. 잭나이프·бут스트랩의 고전적 추정 대상.
- **피어슨/이탈도 잔차** — GLM에서 분산함수·우도 기여분으로 표준화한 잔차. бут스트랩 재료로 쓰인다.
- **체인래더 (chain-ladder)** — 런오프 삼각형의 열 비례성을 이용해 준비금을 추정하는 표준 기법.
- **예측오차 (prediction error)** — 추정분산(모수 불확실성)과 과정분산(미래의 무작위성)을 합친 미래값 오차.
- **산포모수와 자유도 보정** — бут스트랩 분산은 모수 개수를 무시하므로 $n/(n-p)$ 류의 보정이 필요하다.
- **MCMC** — 마르코프 연쇄 몬테카를로. 베이지 사후분포에서 표본을 만드는 시뮬레이션 기법.
- **백분위수 신뢰구간 (percentile interval)** — бут스트랩 복제값들의 $\alpha/2$, $1-\alpha/2$ 분위수로 만드는 구간.

원문: Encyclopedia of Actuarial Science (Wiley, 2004), “Resampling”, Richard Verrall. · 본 해설서의 [해설]·[예제]·[부록]은 학부 입문 학습용으로 추가·구성한 것임. 수식은 원문 기준 복원.