

# 정보기준 (Information Criteria)

출처: Encyclopedia of Actuarial Science (Wiley, 2004)

읽는 법. 본문은 원문 표제어의 내용을 그대로 옮긴 것입니다. 회색 **해설** · **예제** 상자는 학부 입문 학습을 돕기 위해 새로 추가한 부분이며, 원문에는 없습니다. 처음 보는 용어는 글 끝 **부록(보험·통계 용어 풀이)**을 참고하세요.

## 1. 아카이케 정보기준 AIC Akaike's Information Criterion

가장 깊이 연구되고 널리 쓰이는 정보기준은 아카이케(Akaike, 1973)의 정보기준이다. 이것은 **고려 중인 모형과 미지의 자료생성 과정 사이의 쿨백-라이블러(Kullback-Leibler) 거리**의 기대값을 추정해 만든 것이다.  $g(\cdot)$ 를 참 자료생성 밀도,  $f(\cdot; \theta)$ 를 모수벡터  $\theta$ 를 갖는 밀도족(모형)이라 하면,  $g$ 와  $f$  사이의 쿨백-라이블러 거리는

$$KL(g, f) = \int g(x) \log \left( \frac{g(x)}{f(x; \theta)} \right) dx \quad (1)$$

이다. 참 밀도  $g$ 도 모수  $\theta$ 도 미지이므로 이 양은 곧바로 쓸 수 없다. 먼저  $\theta$ 를 최대우도 추정량  $\hat{\theta}$ 로 대체해 추정된 KL 거리를 얻고,  $\theta$ 가 확률변수이므로 그 기대값

$$E\{\widehat{KL}(g, f)\} = \iint g(y) g(x) \log \left( \frac{g(x)}{f(x; \hat{\theta})} \right) dx dy \quad (2)$$

을 생각한다. 이 기대값은 두 항의 차로 쓸 수 있는데, 첫째 항은  $g$ 에만 의존해 모든 후보 모형에 공통이고, 둘째 항은 기대 로그밀도다. 아카이케는 이를 자료의 최대화된 로그우도  $\log L(\hat{\theta}) = \sum \log f(x_i; \hat{\theta})$ 로 추정하자고 제안했고, 이 추정 단계의 **편향이 근사적으로  $\dim(\theta)$ (모수벡터의 성분 개수)임을 보였다**. 그 결과가 모형  $f(\cdot; \theta)$ 의 AIC 값이다:

$$AIC\{f(\cdot; \theta)\} = 2\log L(\hat{\theta}) - 2\dim(\theta) \quad (3)$$

여러 모형  $f_1(\cdot; \theta_1), \dots, f_m(\cdot; \theta_m)$  가운데서는 각각의 AIC 값을 만들어 **가장 큰 모형**을 고른다. 이 형태는 **벌점화 로 그우도**다 — 적합도( $\log L$ )에서 복잡도(모수 수)를 벌점으로 깎는다. 부호를 바꿔  $-2\log L + 2\dim(\theta)$ 를 **최소화**하는 표기도 흔히 쓰인다. 중요한 점은, AIC와 그 파생 기준들을 만드는 데 **참 밀도  $g$ 에 대한 지식이 전혀 필요 없다**는 것이다.

**소표본 보정과 변형.** 표본이 작을 때 Hurvich & Tsai(1989)는 2차 편향 보정을 제안했다:

$$AIC_C = 2\log L(\hat{\theta}) - \frac{2n\dim(\theta)}{n - \dim(\theta) - 1} = AIC - \frac{2\dim(\theta)(\dim(\theta) + 1)}{n - \dim(\theta) - 1} \quad (4)$$

다케우치(Takeuchi, 1976)의 보정은  $\dim(\theta)$  대신 행렬곱  $J(\theta)I^{-1}(\theta)$ 의 대각합(trace)을 쓴다. 여기서  $J(\theta) = E\{(\partial/\partial\theta)\log L\}(\partial/\partial\theta)\log L^T\}$ ,  $I(\theta) = E\{-(\partial^2/\partial\theta\partial\theta^T)\log L\}$ 이다:

$$TIC = 2\log L(\hat{\theta}) - 2\text{tr}\{J(\hat{\theta})I^{-1}(\hat{\theta})\} \quad (5)$$

모형이 참( $f=g$ )이면  $J(\theta)=I(\theta)$ (둘 다 피셔 정보행렬)가 되어 TIC는 AIC로 환원된다. 다만 이 행렬들의 계산·추정이 모든 모형에서 쉬운 것은 아니다. 그 밖에 신경망용 NIC, 준우도(quasi-likelihood)·준모수 및 가법모형 선택에의 응용 등 확장이 있고, 다중회귀·시계열에서의 응용 사례가 풍부하다.

### 해설 AIC의 직관 — "적합도와 단순함의 환율"

모수를 하나 추가하면 로그우도는 반드시 (조금이라도) 올라간다. AIC는 "모수 1개 추가의 값어치는 로그우도 +1 이상이어야 한다"는 환율을 정한 것이다. 핵심 철학은 **참 모형을 맞추는 것이 아니라 예측을 잘하는 모형을 고르는 것** — KL 거리가 바로 "이 모형으로 미래 자료를 기술할 때의 정보 손실"이기 때문이다. 그래서 AIC는 참 모형이 후보에 없어도(현실의 보험자료가 대개 그렇다) 의미를 가진다.

## 2. 베이즈 정보기준 BIC와 DIC Bayesian information criteria

**BIC**(Schwarz 1978, Rissanen 1989)는 모수 개수에 **표본크기의 로그**를 곱해 벌점화한다:

$$BIC\{f(\cdot; \theta)\} = 2\log L(\hat{\theta}) - \log(n) \dim(\theta) \quad (6)$$

이 기준은 자료가 주어졌을 때 **모형의 사후확률의 로그**를 근사하는 데서 나온다. 참 자료생성 모형이 후보 모형족 안에 있다면 BIC는 **일치적으로(consistently) 옳은 모형을 골라낸다**(지수족에서의 증명은 Haughton 1989). 이 가정이 성립하지 않으면 BIC가 고른 모형은 **과소적합**(모수를 너무 적게 사용)하는 경향이 있다.

**DIC**(Spiegelhalter et al. 2002) 역시 베이즈 방법에 기초한다.  $f(x|\theta)$ 를  $\theta$ 가 주어진  $X$ 의 밀도,  $h(x)$ 를 미지량에 의존하지 않는 완전히 지정된 자료의 함수라 하고(예: 지수족에서  $h(x)=P(X=x|\mu(\theta)=x)$ ), **베이즈 이탈도**를

$$D(\theta) = -2\log f(x|\theta) + 2\log h(x) \quad (7)$$

로 정의한다. 벌점항은 이탈도의 사후평균과 사후평균 모수에서의 이탈도의 차  $p_D = \bar{D}(\theta) - D(\theta)$ 이고,

$$DIC = D(\bar{\theta}) + 2p_D \quad (8)$$

이다. DIC는 **최소화**해 모형을 고른다.  $p_D$ 는 "유효 모수 개수"로 해석되며, MCMC 출력에서 바로 계산되어 베이즈 계층모형에서 특히 실용적이다.

### 예제 AIC와 BIC가 다른 모형을 고르는 경우

클레임 심도자료  $n=200$ 건에 (A) 지수분포(모수 1개,  $\log L=-1310.0$ ), (B) 감마분포(2개,  $-1306.5$ ), (C) 일반화 파레토(3개,  $-1305.2$ )를 적합했다. AIC와 BIC(둘 다 "클수록 좋음" 형태)는 각각 어느 모형을 고르는가?

$$AIC_A = -2622.0, \quad AIC_B = -2617.0, \quad AIC_C = -2616.4$$

$$\log 200 = 5.298 : BIC_A = -2625.3, \quad BIC_B = -2623.6, \quad BIC_C = -2626.3$$

AIC는  $C(-2616.4)$ 가 최대를, BIC는  $B(-2623.6)$ 가 최대를 고른다. 모수 1개당 벌점이 AIC는 2, BIC는  $\log n \approx 5.3$ 이라 BIC가 더 검소한 모형을 선호한 것이다.  $n$ 이 커질수록 이 차이는 벌어진다 — 예측 정확도가 목적이면 AIC(C), 구조의 식별·해석이 목적이면 BIC(B)를 따르는 것이 통상의 지침이다.

### 3. 초점 정보기준 FIC The focused information criterion

평균 추정에 가장 좋은 모형과 분산 추정용으로 만든 모형은 다를 수 있다. FIC(Claeskens & Hjort 2003)의 출발점은 — **"최선의 모형"은 관심을 둔 초점 모수(focus parameter)에 따라 달라진다**는 것이다. 하나의 모형이 자료의 모든 측면을 설명하고 모든 유형의 미래 관측을 예측하리라 기대해서는 안 되며, FIC는 관심 모수에 맞춰 재단된 선택을 한다.

구성은 이렇다. 길이  $p$ 의  $\theta$ 를 갖는 좁은 모형  $f(x;\theta)$ 에 추가 모수  $q$ -벡터  $\gamma$ 를 붙인 확장 모형  $f(y;\theta,\gamma)$ 를 두고( $\gamma=\gamma_0$ 이면 좁은 모형),  $\mu(\theta,\gamma)$ 를 초점 모수(예: 주어진 공변량에서의 평균 반응)라 하자. 과제는  $q$ 개의 추가 모수 중 어느 부분집합  $S \subset \{1, \dots, q\}$ 를 포함할지 정하는 것이다. 정보행렬을  $l_{00}(p \times p)$ ,  $l_{01}$ ,  $l_{10}$ ,  $l_{11}$ 로 분할하고  $K = (l_{11} - l_{10}l_{00}^{-1}l_{01})^{-1}$ ,  $\omega = l_{10}l_{00}^{-1}(\partial\mu/\partial\theta) - (\partial\mu/\partial\gamma)$ , 부분집합별  $K_S = (\pi_S K^{-1} \pi_S^t)^{-1}$ ,  $H_S = K^{-1/2} \pi_S^t K_S \pi_S K^{-1/2}$ ,  $\delta = \sqrt{n}(\hat{\gamma}_{full} - \gamma_0)$ 을 정의하면(모두 최대 모형에서 일치추정 가능), FIC는 위험(리스크) 차이에 기초해

$$FIC_S = (\hat{\psi}_{full} - \hat{\psi}_S)^2 + 2 \hat{\omega}_S^t \hat{K}_S \hat{\omega}_S, \quad \hat{\psi}_{full} = \hat{\omega}^t \hat{\delta} \quad (9)$$

로 주어지고( $\hat{\psi}_S = \hat{\omega}_S^t \hat{K}_S^{-1/2} \hat{H}_S \hat{K}^{-1/2} \hat{\delta}$ ), **FIC 값을 최소화**하는 모형을 고른다.  $K$ 가 대각이면 다음처럼 단순해진다:

$$FIC_S = \left( \sum_{j \notin S} \hat{\omega}_j \hat{\delta}_j \right)^2 + 2 \sum_{j \in S} \hat{\omega}_j^2 \hat{K}_{jj} \quad (10)$$

첫째 항은 변수를 빼서 생기는 **편향**<sup>2</sup>, 둘째 항은 변수를 넣어 생기는 **분산**에 대응한다 — 초점 모수의 평균제곱오차를 부분집합별로 가능하는 셈이다.

#### 심화 해설 보험계리에서의 모형선택 — 어느 기준을 쓰나

손해분포 적합(지수 vs 감마 vs 파레토), 요율 GLM의 변수 선택, 사망률 모형(리-카터류)의 차수 결정, 준비금 모형 비교까지 — 계리 실무의 거의 모든 단계에 모형선택이 숨어 있다. 통상 AIC/BIC를 병기해 보고하되, 둘이 갈리면 목적을 묻는다: **요율·준비금 같은 예측이 목적이면 AIC 계열**, 위험요인의 유의성 판단처럼 **구조 식별이 목적이면 BIC**. 그리고 FIC의 교훈은 보험에 특히 잘 맞는다 — 99.5% VaR(꼬리 분위수)를 추정하는 데 최선인 모형은 평균 손해액 추정에 최선인 모형과 다를 수 있다. 같은 자료라도 "무엇을 위해 고르는가"를 먼저 정해야 한다.

## 참고 및 관련 표제어

**관련 표제어.** Hidden Markov Models(은닉 마르코프 모형) · Logistic Regression Model(로지스틱 회귀모형) · Maximum Likelihood(최대우도) · Bayesian Statistics(베이지 통계)

**원문 참고문헌(발췌).** Akaike, 2nd Int. Symp. Information Theory (1973) · Schwarz, Annals of Statistics 6 (1978) · Hurvich & Tsai, Biometrika 76 (1989) · Takeuchi, Suri-Kagaku 153 (1976) · Spiegelhalter, Best, Carlin & van der Linde, JRSS B 64 (2002) · Claeskens & Hjort, JASA 98 (2003) · Burnham & Anderson, Model Selection and Multimodel Inference (Springer, 2002) · Linhart & Zucchini, Model Selection (Wiley, 1986).

## 부록. 이 글에 나온 용어 (배경지식 보충)

- **쿨백-라이블러 거리 (Kullback-Leibler distance)** — 참 분포  $g$  대신 모형  $f$ 를 쓸 때의 평균 정보 손실. 0 이상이며  $f=g$ 일 때만 0.
- **최대우도 추정량  $\hat{\theta}$  (MLE)** — 관측자료의 우도  $L(\theta)$ 를 최대화하는 모수값.
- **벌점화 로그우도 (penalized log-likelihood)** — 적합도에서 모형 복잡도 벌점을 뺀 기준. AIC·BIC의 공통 골격.
- **피셔 정보행렬 (Fisher information matrix)** — 로그우도 기울기의 분산(=2계 도함수 기대값의 음수). 모수 추정 정밀도의 척도.
- **대각합  $\text{tr}$  (trace)** — 정방행렬 대각원소의 합. TIC의 벌점항.
- **일치성 (consistency)** — 표본이 커질수록 옳은 답(여기서는 참 모형)에 확률적으로 수렴하는 성질. BIC의 장점.
- **과소적합/과대적합 (underfit/overfit)** — 모수가 너무 적어 구조를 놓침/너무 많아 잡음까지 학습함.
- **사후확률 (posterior probability)** — 자료를 관측한 뒤의 모형(또는 모수) 확률. BIC가 그 로그를 근사.
- **유효 모수 개수  $p_D$**  — DIC의 벌점항. 계층모형처럼 모수 수가 모호할 때의 실질적 복잡도.
- **초점 모수 (focus parameter)** — 분석의 최종 관심량(평균 반응, 순위수, 비율 등). FIC는 이것별로 모형을 고른다.
- **준우도 (quasi-likelihood)** — 분포 전체 대신 평균-분산 관계만 지정해 만드는 우도 유사물. 과산포 모형에 사용.

원문: Encyclopedia of Actuarial Science (Wiley, 2004), "Information Criteria", Gerda Claeskens. · 본 해설서의 [해설]·[예제]·[부록]은 학부 입문 학습용으로 추가·구성한 것임. 수식은 원문 기준 복원.